




RL과 ICL로 수능 수학 정복하기

- 정말 할 수 있을까요? -

0장: 그래서 뭘 한다고요?

기념비

데이터&모델 크기 = k성능




데이터&모델 크기 = k성능

Loss $\propto$ 1/성능



학습량 $\propto$ 학습시간



talent pool

동사가 한국 법인으로 시작한 가장 큰 이유는 **인재 채용의 용이성**으로 추정된다. 한국은 다음과 같은 3가지 특성을 동시에 지니고 있어 특별하다. 첫째, **인재의 수준이 높다**: 탑클래스 반도체 기업과 이를 키워낸 기관이 있다. 둘째, **인재의 밀도가 높다**. 한국의 지리적 특성 때문에 인재들이 좁은 패킷에 모여있다: 기업은 삼성전자, SK하이닉스, 그리고 학계는 서울대학교, POSTECH, KAIST (SPK).

마지막으로, **최고의 인재들에게 매력적으로 보이는 moonshot** 프로젝트를 국내에서 찾기 힘들다. 엔비디아에 맞선다는 비전과 삼성전자의 바통을 받는다라는 **bold**한 주장은 마음속의 불꽃을 피어오르게 할만하다.

Where are we now?

Training Compute-Optimal Large Language Models, 2022

Approach	Coeff. a where $N_{opt} \in C^a$	Coeff. b where $D_{opt} \in C^b$
1. Minimum over training curves	0.50 (0.488, 0.502)	0.50 (0.501, 0.512)
2. IsoFLOP profiles	0.49 (0.462, 0.534)	0.51 (0.483, 0.529)
3. Parametric modelling of the loss	0.46 (0.454, 0.455)	0.54 (0.542, 0.543)
Kaplan et al. (2020)	0.73	0.27

$O(\text{지능}) \propto \text{root}(\text{컴퓨팅})$

최적의 성능(loss)을 얻을 때는,
컴퓨팅의 제공근에 대략적으로 비례

Where are we now?

$O(\text{지능}) \propto \text{root}(\text{컴퓨팅})$

+ SFT RLHF.. LoRA
for aligning

$O(\text{지능}) \propto \text{컴퓨팅}$

지능의 선형적 증가

=

scaling law based 친구들 추월가능

새로운 방법을 찾아야 한다.

Pre-training as we know it will end

Compute is growing:

- Better hardware
- Better algorithms
- Larger clusters


Data is not growing:

- We have but one internet
- **The fossil fuel of AI**

Ilya Sutskever: "Sequence to sequence learning with neural networks: what a decade"

$O(\text{지능}) \propto \text{컴퓨팅}$

+ 제한된 양질의 데이터로 생각
할 수 있도록 해야함



ex) think at inference time



Towards AGI
: searching for next big thing

Agent

collective intelligence

- Merging Models
- Agentic System (Recommend!)

Sampling

think at inference time

- MCTS (alphago)
- Entropy based approach

Towards AGI

: searching for next big thing

Hyper Training

- AI researcher
- Non-differential Training (decision, hyperparams...)


Bio

- Connectom (map of brain)
- BCI (upgrade human)
- Organoid


1장 : Deep Learning Circuit

인공지능은 어떻게 배우냐?


직관적으로 알아보자.



학습




학습을 한다는 것은 일종의 “일반화+압축”으로 볼 수 있다



신장(cm)	다리길이(cm) 키 X 0.52	허벅지길이(cm) 다리길이 X 0.45	무릎이하(cm) 다리길이 X 0.55
150	78.00	35.10	42.90
152	79.04	35.57	43.47
154	80.08	36.04	44.04
156	81.12	36.50	44.62
158	82.16	36.97	45.19
160	83.20	37.44	45.76
162	84.24	37.91	46.33
164	85.28	38.38	46.90
166	86.32	38.84	47.48
168	87.36	39.31	48.05
170	88.40	39.78	48.62

평면상에 있는 점들의 위치를 나타내는 데이터에서도 이상치를 발견할 수 있다. 대부분의 점들이 가상의 직선 주위에 모여 있다면 이 직선은 데이터의 특징을 잘 나타낸다고 할 수 있다. 이 직선을 직선 L 이라고 하자. 그런데 직선 L 로부터 멀리 떨어진 위치에도 몇 개의 점이 있다. 이 점들이 이상치이다.



최적의 직선을 찾아보자.


$$\begin{bmatrix} x_1 & 1 \\ x_2 & 1 \\ \vdots & \vdots \end{bmatrix} \begin{bmatrix} m \\ b \end{bmatrix} = \begin{bmatrix} y_1 \\ \vdots \end{bmatrix}$$

|||

$$mX + b = y$$



최적화



차이를 최소화하는 방향으로
점진적 업데이트




수학적

X의 열공간에 Y를
projection하여 최선의 직선
을 찾아낸다

더 확장해보자



최적화




차이를 최소화하는 방향으로
점진적 업데이트

= Loss(손실)의 최소화

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

확장의 필요성




간단한 선이 아니다!!

비선형성의 필요성 대두


$$m_2(m_1x + b_1) + b_2 \\ \parallel \\ mx + b$$

간단한 선이 되어버려!!


비선형성 추가
 $\parallel$
Activation



살아볼까요?





1 layer X N



복잡한 feature의
처리가 용이해짐!

Inside the black box what's going on?




확장의 필요성



← 학습

간단한 선이 아니다!!

re: 인공지능은 어떻게 배우냐?



→ 이 해괴한 친구는 뭐야?

미분 = 건들면 누가 얼마나 화나니?

가장 예민한 친구는 누구죠

$f(g(x))$ 의 미분을 각각 생각해보자.

$$t=g(x)$$
$$y=f(t)$$




$$dt=g'(x)dx$$
$$dy=f'(t)dt$$

dt와 dx의 비율은 $g'(x)$ 이다.
=
x를 때리니 t가 이만큼 화나구나



re: 인공지능은 어떻게 배우냐?



우리가 학습하고자 하는 m 과 x 가
얼마나 Loss를 화나게(미분) 하는
지를 알 수 있다.



화나게 하는 방향과 반대로
+
화나게 하는 정도에 비례해서
값을 업데이트하자!

re: 인공지능은 어떻게 배우냐?

분노 게이지에 비례하여

화나게 하는 방향과 반대로

$$*W_x = W_x - \alpha \left(\frac{\partial \text{Error}}{\partial W_x} \right)$$

New weight

Learning rate

The diagram illustrates the weight update formula for a neural network. The formula is $*W_x = W_x - \alpha \left(\frac{\partial \text{Error}}{\partial W_x} \right)$. Annotations include: 'Old weight' pointing to W_x , 'New weight' pointing to $*W_x$, 'Learning rate' pointing to α , and '분노 게이지에 비례하여' (proportional to the anger gauge) pointing to the derivative term. A red oval highlights the derivative term, and a red circle highlights the minus sign. A red arrow points from the derivative term to the minus sign, indicating the direction of the update.

re: 인공지능은 어떻게 배우냐?

분노 게이지에 비례하여

화나게 하는 방향과 반대로


$$*W_x = W_x - \alpha \left(\frac{\partial Error}{\partial W_x} \right) \times N\text{번 반복}$$

New weight

Learning rate

re: 인공지능은 어떻게 배우냐?

re: 인공지능은 뭘 배우냐?



Loss는 뭐지?


MLE
(Maximum Likelihood Estimation)

$$\operatorname{argmax}_{\theta} \log(\text{data}|H) = \operatorname{argmax}_{\theta} \log(y|\hat{y})$$




데이터가 모델에서 관측될 우도를 최대화한다!!

혁펜하임 유튜브 참고: <https://www.youtube.com/watch?v=M6Hf6R8byvM>

re: 인공지능은 뭘 배우냐?



인공신경망





$$P(x) = \alpha e^{-\frac{(x-\mu)^2}{\beta}}$$

$$P(y|\hat{y}) = \alpha e^{-\frac{(y-\hat{y})^2}{\beta}}$$

$$\log P(y|\hat{y}) = -k(y-\hat{y})^2 + m$$


$$\operatorname{argmax} \log P(y|\hat{y}) = -(y-\hat{y})^2$$

re: 인공지능은 뭘 배우냐?



가우시안


re: 인공지능은 뭘 배우냐?



베르누이 분포

$$P(y|w) = p^y (1-p)^{1-y}, y \in 0, 1$$

conclusion: 인공지능은 어떻게 배우냐?





분노 게이지에 비례하여

화나게 하는 방향과 반대로


$$*W_x = W_x - \left(\frac{\partial \text{Error}}{\partial W_x} \right)$$

New weight Learning rate

conclusion: 인공지능은 어떻게 배우냐?




conclusion: 인공지능은 어떻게 배우냐?



그것이 알고 싶다

여기서 무엇이 문제일까.

이것만으로는 부족하다..!



VS.




$$\frac{dLoss}{dx_1} = \frac{dLoss}{dx_{n-1}} \times \dots \times \frac{dx_2}{dx_1}$$

이것만으로는 부족하다..!

$$\frac{dLoss}{dx_1} = \frac{dLoss}{dx_{n-1}} \times \dots \times \frac{dx_2}{dx_1}$$




- 모두 1 초과이면 발산!
- 모두 1 미만이면 0




VS.



지금까지의 노력들...



Going Deeper with Convolutions –
GoogLeNet(2014)



Visualizing the Loss Landscape of
Neural Nets(2017)

Normalizations: Batch Norm, Layer Norm, ...

Regularization(MAP): Weight Decay, Clip Norm, ...

Optimizing: SGD, Momentum, Riemannian Metric, ...

+인공지능이 어떻게 잘 배우게 함?

Inductive Bias

- 보기
- 읽기, 예측하기

+인공지능이 어떻게 잘 배우게 함?

Inductive Bias

- 보기

- 읽기, 예측하기

Spatial한 특징을 아까본 연산으로 살리기 어렵다

=> 2차원이라는 것 + 하나하나 픽셀보다 주변과의 관계 중요

0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	1	12	0	11	39	137	37	0	152	147	84	0	0	0	0
0	0	1	0	0	0	41	160	250	255	235	162	255	238	206	11	13	0	0
0	0	0	16	9	9	150	251	45	21	184	159	154	255	233	40	0	0	0
10	0	0	0	0	0	145	146	3	10	0	11	124	253	255	107	0	0	0
0	0	3	0	4	15	236	216	0	0	38	109	247	240	169	0	11	0	0
1	0	2	0	0	0	253	253	23	62	224	241	255	164	0	5	0	0	0
6	0	0	4	0	3	252	250	228	255	255	234	112	28	0	2	17	0	0
0	2	1	4	0	21	255	253	251	255	172	31	8	0	1	0	0	0	0
0	0	4	0	163	225	251	255	229	120	0	0	0	0	0	11	0	0	0
0	0	21	162	255	255	254	255	126	6	0	10	14	6	0	0	9	0	0
3	79	242	255	141	66	255	245	189	7	8	0	0	5	0	0	0	0	0
26	221	237	98	0	67	251	255	144	0	8	0	0	7	0	0	11	0	0
125	255	141	0	87	244	255	208	3	0	0	13	0	1	0	1	0	0	0
145	248	228	116	235	255	141	34	0	11	0	1	0	0	0	1	3	0	0
85	237	253	246	255	210	21	1	0	1	0	0	6	2	4	0	0	0	0
6	23	112	157	114	32	0	0	0	0	2	0	8	0	7	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0

+인공지능이 어떻게 잘 배우게 함?

Inductive Bias

- 보기

- 읽기, 예측하기

더 알아보기 -> CS231n Winter

α	β
γ	δ

applied to

A	B	C
D	E	F
G	H	J

yields

P	

α	β
γ	δ

A	B	C
D	E	F
G	H	J

	Q

α	β
γ	δ

A	B	C
D	E	F
G	H	J

R	

α	β
γ	δ

A	B	C
D	E	F
G	H	J

	S

100

+인공지능이 어떻게 잘 배우게 함?

Inductive Bias

Sequence 시계열

$h \rightarrow e \rightarrow l \rightarrow l \rightarrow ?$

- 보기


- 읽기, 예측하기

?에 무엇이 들어갈지는 hell까지
순차적인 정보를 살려 예측해야함

+인공지능이 어떻게 잘 배우게 함?

Embedding 임베딩

안녕 -> [0, 2, 6, 3, 1, 5]



왕 - 남자 + 여자 => 여왕


+인공지능이 어떻게 잘 배우게 함?


Inductive Bias

- 보기

- 읽기, 예측하기


Sequence 시계열





+인공지능이 어떻게 잘 배우게 함?

아키텍처의 끝판왕 = Transformer



내적 = 두 친구 사이의 유사도



데이터를 처리할 때
어디에 집중해야 할지를 제시

re: 인공지능은 어떻게 배우냐?

