

대학원생 하강법 vs 프론티어랩 하강법

Magic Number all you need.

Magic Numbers

- 0x5f3759df
- 998244353 ps
- 42
- 1729 택시수
- 1.69 Chinchilla Scaling (20 token/param)
- 0.001 기본적인 Learning rate
- 50257 GPT-2 Vocab Size
- 416 My birthday!! 🎂
- 1472 일사천리: 뽀뽀암호
- 127.0.0.1
- 6.02×10^{23}
- 67
- linear(dim, 3 x dim)


```
float Q_rsqrt( float number )
{
    long i;
    float x2, y;
    const float threehalfs = 1.5F;

    x2 = number * 0.5F;
    y = number;
    i = * ( long * ) &y;           // evil floating p
    i = 0x5f3759df - ( i >> 1 );  // what the fuck?
    y = * ( float * ) &i;
    y = y * ( threehalfs - ( x2 * y * y ) ); // 1st iteration
    // y = y * ( threehalfs - ( x2 * y * y ) ); // 2nd iteration,

    return y;
}
```

fast inverse sqrt

42



삶,우주,그리고 모든 것에 대한 궁극적인 질문의 해답

```
class Block(nn.Module):
    """ an unassuming Transformer block """
    def __init__(self, config):
        super().__init__()
        self.ln_1 = nn.LayerNorm(config.n_embd)
        self.attn = CausalSelfAttention(config)
        self.ln_2 = nn.LayerNorm(config.n_embd)
        self.mlp = nn.ModuleDict(dict(
            c_fc = nn.Linear(config.n_embd, 4 * config.n_embd),
            c_proj = nn.Linear(4 * config.n_embd, config.n_embd),
            act = NewGELU(),
            dropout = nn.Dropout(config.resid_pdrop),
        ))
        m = self.mlp
        self.mlpf = lambda x: m.dropout(m.c_proj(m.act(m.c_fc(x)))) #
```


왜 하필이면 x4지? 무슨 이유?
어디서 굴러온 숫자입니까!!!

대학원생 하강법

Magic Number을 찾기 위한 몸부림



<출처: 서울대저널TV>



대학원생 하강법

Magic Number를 찾기 위한 몸부림

5.3.2 대학원생 하강법

좋은 하이퍼파라미터를 얻는 가장 간단한 방법은 수동으로 서로 다른 숫자의 하이퍼파라미터 넣고 어떻게 작동하는지 확인하는 것입니다. 이 전략은 놀랄 만큼 효과적이고 교육적일 수 있습니다. 딥러닝 실무자는 딥 네트워크 구조에 대한 직관력을 기를 필요가 있습니다. 이론이 약할 때는 경험적으로 연구하는 것이 딥러닝 모델을 만드는 방법을 학습하는 최고의 방법입니다. 스스로 다양한 완전연결 모델을 만들어보기 바랍니다. 하이퍼파라미터 선택 사항과 결과를 스프레드시트에 기록하고 체계적으로 탐구하십시오. 다양한 하이퍼파라미터의 효과를 이해하려고 노력하십시오. 무엇이 네트워크 학습 과정을 더 빠르게 또는 더 느리게 하나요? 어떤 설정 범위에서 학습은 완전히 중단되나요? (불행히도 이것은 알기 쉽습니다.)

이와 같이 하이퍼파라미터 값을 고르는 방법을 대학원생 하강법이라고 부르는 이유는 무엇일까요? 최근까지 머신러닝은 주로 학문적인 영역이었습니다. 새로운 머신러닝 알고리즘을 설계하기 위한 신뢰할 수 있는 방법은 신입 대학원생에게 원하는 방법을 설명하고 그들이 세부 사항을 해결하도록 만드는 것이었습니다. 이러한 과정은 일종의 통과 의례이며 학생들은 수많은 설계 대안을 시도해야 했습니다. 전반적으로 이것은 교육적인 경험입니다. 왜냐하면 설계 미학을 얻는 유일한 방법은 동작하는 설정과 동작하지 않는 설정에 대한 기억을 쌓는 것이기 때문





Adam

위에

위에


Network



대학원생


대학원생 하강법

을 사용하는 인공지능(?) - Autoresearch by Andrej Karpathy



프론티어랩 하강법

Magic Number을 설명하자.




1.3B 훈련 with 1.5T tokens = 50000시간(A100) = 1억(Runpod)
Llama 3.1 70B = 2천만 시간(B100) = ~400억

42dot LLM 1.3B, <https://42dot.ai/blog/178>

1. 귀납법

Model의 성능을 좌우하는 변수들



Lottery 뽑기는 위험하다

프론티어랩 하강법

Magic Number을 설명하자.

1. 귀납법

Model의 성능을 좌우하는 변수들

모델 성능은 C, D, N에 대한 함수이다.

Compute, Dataset, Parameter

C, D, N에 대해서 단조 증가하는 추세를 찾음! = **Scaling Law**

현재는 RL/Coding/Agent

네이버에서 LLM 개발을 한다는 것, <https://yozm.wishket.com/magazine/detail/3276/>

실제 랩에서도 GPU farm에서 수많은 axis(데이터셋 품질) 중에 단조증가하는 추세를 찾고, 이를 밀어붙이는 방식을 사용한다


프론티어랩 하강법

Magic Number을 설명하자.

1. 신경과학 접근
2. 통계학적 접근

3. Representation 접근

일반화= '데이터의 표현' 찾아내기



2. 수학

아름다움을 추구한다면

