

N-gram from scratch (1)

todo: 멋진 것 만들기

뉴비..를 위한 인공지능이 재밌어지는 시간!

top-down으로 공부하다간 끝나지 않는걸 깨달

bottom-up으로 직접 만들면서 배워보자

From Scratch 철학 전도사



뉴비..를 위한 인공지능이 재밌어지는 시간!

문제 정의:

```
1  날개
2
3  이상
4
5  '박제가 되어 버린 천재'를 아시오? 나는 유쾌하오. 이런 때 연애까지가 유쾌하오.
6  육신이 흐느적흐느적하도록 피로했을 때만 정신이 은화처럼 맑소. 니코틴이 내 횃배 앓는
   바둑 포석처럼 늘어놓소. 가증할 상식의 병이오.
7  나는 또 여인과 생활을 설계하오. 연애 기법에까지 서먹서먹해진 지성의 극치를 흘긋 들어
   반이오 - 만을 영수하는 생활을 설계한다는 말이오. 그런 생활 속에 한 발만 들여놓고 흡
   건딜 수가 없게끔 되고 그만둔 모양이오. 굿바이.
```

이상처럼 글을 쓰는(뭐든지 상관없음) 모델을 만들고 싶다.

왜 수확인가..에 대한 초보의 대답

(1) THE ROOM WAS NOT VERY LIGHT A SMALL OBLONG
(2) ----ROO-----NOT-V-----I-----SM----OBL-----
(1) READING LAMP ON THE DESK SHED GLOW ON
(2) REA-----O-----D----SHED-GLO--O--
(1) POLISHED WOOD BUT LESS ON THE SHABBY RED CARPET
(2) P-L-S-----O---BU--L-S--O-----SH-----RE--C-----

reduced text

TABLE I

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	100
1	18.2	29.2	36	47	51	58	48	66	66	67	62	58	66	72	60	80
2	10.7	14.8	20	18	13	19	17	15	13	10	9	14	9	6	18	7
3	8.6	10.0	12	14	8	5	3	5	9	4	7	7	4	9	5	
4	6.7	8.6	7	3	4	1	4	4	4	4	5	6	4	3	5	3
5	6.5	7.1	1	1	3	4	3	6	1	6	5	2	3			4
6	5.8	5.5	4	5	2	3	2			1	4	2	3	4	1	2
7	5.6	4.5	3	3	2	2	8		1	1	1	4	1		4	1
8	5.2	3.6	2	2	1	1	2	1	1	1	1		2	1	3	
9	5.0	3.0	4		5	1	4		2	1	1	2		1		1
10	4.3	2.6	2	1	3		3	1					2			
11	3.1	2.2	2	2	2	1			1	3		1	1	2	1	
12	2.8	1.9	4		2	1	1	1			2	1	1		1	1
13	2.4	1.5	1	1	1	1	1	1	1	1		1	1			
14	2.3	1.2		1			1					1				1
15	2.1	1.0	1	1							1	1	1			
16	2.0	.9					1			1					1	
17	1.6	.7	1		2	1	1				1		2	2		
18	1.6	.5													1	

Shannon, Prediction and Entropy of Printed English (1950)

<http://bit.ly/ngramyoonhero>

뉴비..를 위한 인공지능이 재밌어지는 시간! - #define problem

n-gram: n개의 인풋을 보고 -> 다음 올 것을 예측!

_아내 -> 의

```
def logistic(x):
    indexs = tokenize(x)
    x = Emb[indexs].reshape(-1)
    y = W @ x + B
    exped = np.exp((y-y.max())) / 0.5
    softmaxed = exped / np.sum(exped, keepdims=False)
    return np.random.choice(len(softmaxed), p=softmaxed)

generate("박제가_되어버린_", logistic, max_length=50).replace(" ", "_")
337] ✓ 0.0s
.. '박제가_되어버린_아내는_내_가__아는다._나는다._그러._그는_마_이지_않이_아내지_내_이'

generate("슬픈_", logistic, max_length=50).replace(" ", "_")
338] ✓ 0.1s
.. '슬픈_아내__아는_내_이지_지_가_하하이_아내의_내_하충다._그는_것을_그고_아내는_것_아'
```

오늘은 우선 문제가 많은

친구를 만들 예정!

(답에 만나면 문제를 하나씩 수정!)

뉴비..를 위한 인공지능이 재밌어지는 시간! - 데이터 분석

날 32	개 22	165	이 641	상 35	' 14	박 4	제 30	가 320	5444	되 18	어 208	버 32	린 42	천 4	재 9	를 138	아 365	시 59	오 86	? 33	나 456	는 613	유 11	쾌 13
하 295	594	런 39	때 28	연 20	애 4	까 59	지 249	육 3	신 20	흔 9	느 37	적 40	도 185	록 6	피 35	로 122	했 24	을 317	만 79	정 39	은 167	화 28	처 39	럼 37
밖 1	소 47	니 64	코 9	틴 1	내 390	횃 1	배 13	왕 3	뱃 1	숙 48	으 113	스 48	미 34	면 76	머 24	릿 3	에 298	레 5	백 3	준 5	비 33	범 11	그 271	위 23
다 699	트 3	와 34	파 6	라 67	독 2	바 20	독 5	포 8	석 7	늘 35	놓 28	증 10	할 27	식 14	의 154	병 7	또 25	여 83	인 59	과 25	생 57	활 9	설 6	계 16
기 116	서 151	먹 26	해 53	진 16	성 11	극 4	치 28	홀 1	긋 1	들 104	본 12	일 75	있 89	65	말 38	자 75	종 7	분 14	열 16	반 11	15	것 224	은 19	갖 6
영 6	수 64	한 145	발 18	고 290	흡 3	사 68	두 22	태 9	양 12	마 60	주 33	보 96	며 32	깎 3	거 70	리 175	간 43	히 42	행 10	싱 3	워 13	견 14	딜 8	없 117
게 112	꿈 2	둔 1	모 33	긋 4	대 55	따 13	금 17	싫 9	을 29	탐 2	러 98	실 20	같 24	36	조 24	작 15	품 8	번 35	차 19	경 14	편 7	매 6	1 11	9 2
세 26	될 10	든 26	봉 2	쇄 1	토 1	예 4	프 5	키 9	란 12	첫 3	낭 1	불 53	빵 1	각 51	누 11	랬 4	언 3	듯 25	싶 21	혹 5	형 4	디 25	테 3	문 22
야 27	갸 12	부 34	깨 2	" 10	꿍 4	알 82	완 2	줄 10	민 4	감 23	떤 5	우 24	즈 6	(2	원 15	닌 4	르 16	) 2	동 30	딱 6	공 6	급 2	합 3	네 9
범 1	회 12	안 49	목 10	규 1	였 70	왕 1	망 7	많 12	질 10	전 24	논 6	뜻 8	밖 12	험 2	3 11	구 37	곽 1	낌 1	8 9	죽 9	깨 9	맞 9	창 5	호 2
똑 4	궁 3	람 20	송 4	꽃 6	점 2	드 29	른 17	체 16	달 10	덕 2	살 15	밀 5	철 5	얼 33	록 1	널 1	핑 1	단 16	막 4	침 9	방 72	낮 18	잠 38	잔 6
밖 25	알 22	길 11	참 19	옹 8	뿐 16	견 5	등 7	켜 6	뒤 21	칠 3	씬 4	려 52	저 30	물 22	жат 1	빠 4	넌 7	새 14	웃 8	굽 3	탕 1	랑 5	뜨 4	눈 1

Total tokens: 800

Current H: 9.64 (~1024 완전 무작위)

뉴비..를 위한 인공지능이 재밌어지는 시간! - 만들어야 하는 것

```
import random

def beautiful_f(x):
    return random.randint(0, total_tokens)

def generate(x, function, max_length=100):
    for i in range(len(x), max_length):
        x += stringify([function(x[i-n:i])])
    return x

chunk = chunks[0]
x = chunk[:n]
y = chunk[n]
print(generate(x, beautiful_f))
```


날개
봉개왜집궁하새월형냐며덩못운젼코괘뜰넛럽막든면센너퍼뚜콰릿냐막싫페흘팩싸특조
람많멩찌복써써커제림뻘젼랴문엿넬쏘앞닿띄칸뜸런곰들뜨왔튼룩떡논알용털지잉세센참칸큼줄릴듯색엿느겸1만_덜래라걱엿썩뚜

beautiful_f를 우리가 직접 짜는 것..
(*매우 천재만 가능)

수학의 힘을 빌리자!

뉴비..를 위한 인공지능이 재밌어지는 시간! - 오차역전파

미적분학 연습문제를 풀어보죠.




뉴비...를 위한 인공지능이 재밌어지는 시간! - 1번 접근 문제

```
it = list(set(generate("날개는 돋았", simple_linear, W=W, B=B)))
for char in it:
    print(stoi[char] / total_tokens) # 0.5를 출력하는 멍청이..
```

0.51
0.565
0.58
0.58125
0.93625
0.57375
0.5825
0.5675
0.80625
0.5775
0.1325
0.5875
0.215
0.5725
0.55875
0.93
0.57625
0.5075


CLT... 중간에 집중해버림



출력칸을 나누자!

뉴비..를 위한 인공지능이 재밌어지는 시간! - 2번 접근 문제


token의 정보를 줄 수 없음..



token에 벡터를 부여하자!


뉴비..를 위한 인공지능이 재밌어지는 시간! - n이 커지면

n=3



'박제가_되어버린_아내는_내_가__아는
다._나는다._그러._그는_마_이지_않이_아
내지_내_이'

n=6



'박제가_되어버린_아내_내_이_가_이_서_없
_나_이_가_하_가_다_다._나는_이_이_이_
하고'

VS

P(next|context)